



ANALISIS FAKTOR GAYA HIDUP PADA PREDIKSI RISIKO STROKE

MENGGUNAKAN EXPLAINABLE
MACHINE LEARNING

Latar Belakang & Research Gap

Fakta Masalah

Stroke merupakan salah satu **penyebab utama kematian** dan kecacatan di dunia. Identifikasi risiko stroke sejak dini dapat membantu pencegahan dan pengambilan keputusan klinis yang lebih efektif.

Research Gap

Walaupun pola tidur, kondisi mental, dan aktivitas fisik secara medis berkaitan dengan risiko stroke, kontribusi masing-masing kelompok faktor gaya hidup terhadap performa model prediksi masih belum dievaluasi secara komprehensif dan terukur.



Penelitian lain & Inovasi

Penelitian Lain

Shobayo et al. (2023): Prediction of Stroke Disease with Demographic and Behavioural Data Using Random Forest Algorithm
[<https://www.mdpi.com/2813-2203/2/3/34>]

Huang & Liu (2025): Development and validation of a machine learning model to predict stroke risk based on the NHANES database
[<https://pubmed.ncbi.nlm.nih.gov/41204470/>]

Nguyen et al. (2022): Lifestyle practices and associated factors among adults with hypertension: Conquering Hypertension in Vietnam-solutions at the grassroots level study
[<https://pmc.ncbi.nlm.nih.gov/articles/PMC11156363/>]

Inovasi

- Membandingkan 3 algoritma ML (DT, RandomForest, XGBoost)
- Mengukur kontribusi masing-masing kelompok gaya hidup secara independen
- Interpretasi hasil menggunakan SHAP (Explainable AI)



Rumusan Masalah

Bagaimana performa Decision Tree, Random Forest, dan XGBoost dalam memprediksi risiko stroke menggunakan dataset NHANES?

Seberapa besar peningkatan performa model ketika variabel stres/depresi ditambahkan ke fitur klinis standar?

Seberapa besar peningkatan performa model ketika variabel pola tidur ditambahkan ke fitur klinis standar?

Seberapa besar peningkatan performa model ketika variabel aktivitas fisik ditambahkan ke fitur klinis standar?

Kelompok faktor gaya hidup manakah yang memberikan kontribusi terbesar terhadap prediksi risiko stroke berdasarkan analisis SHAP?

Tujuan Penelitian

Membangun Model

Bagaimana performa Decision Tree, Random Forest, dan XGBoost dalam memprediksi risiko stroke menggunakan dataset NHANES?

Perbandingan Algoritma

Membandingkan performa ketiga algoritma menggunakan metrik evaluasi yang sama (Accuracy, Precision, Recall, F1, AUC-ROC).

Evaluasi Gaya Hidup

Mengevaluasi kontribusi masing-masing kelompok faktor gaya hidup (tidur, stres, aktivitas fisik) terhadap peningkatan performa model.

SHAP Analysis

Mengidentifikasi fitur yang paling berpengaruh terhadap prediksi stroke menggunakan SHAP (SHapley Additive exPlanations).

Manfaat Penelitian

Memberikan bukti empiris mengenai kontribusi masing-masing kelompok faktor gaya hidup terhadap prediksi risiko stroke berbasis *machine learning*.

Memberikan analisis interpretatif mengenai faktor-faktor yang memengaruhi keputusan model menggunakan Explainable AI.

Menjadi dasar pengembangan sistem skrining risiko stroke yang mempertimbangkan faktor klinis dan faktor gaya hidup yang dapat dimodifikasi melalui perubahan perilaku.

Metode Penelitian



Dataset

NHANES

- DEMO_I
- MCQ_I
- BMX_I
- BPX_I
- SLQ_I
- DPQ_I
- PAQ_I)

Preprocessing

- Data Cleaning
- Missing Value Handling
- Feature Encoding & Scaling
- SMOTE (class imbalance)

Algoritma ML

- Decision Tree
- Random Forest
- XGBoost

Metrik Evaluasi

- Accuracy
- Precision
- Recall
- F1-Score
- AUC-ROC

Desain Eksperimen

- Faktor Klinis
- Faktor Klinis + Tidur
- Faktor Klinis + Stres/Depresi
- Faktor Klinis + Aktivitas Fisik
- Faktor Klinis + Semua Faktor Gaya Hidup

Referensi

Shobayo et al. (2023): Prediction of Stroke Disease with Demographic and Behavioural Data Using Random Forest Algorithm
[<https://www.mdpi.com/2813-2203/2/3/34>]

Huang & Liu (2025): Development and validation of a machine learning model to predict stroke risk based on the NHANES database
[<https://pubmed.ncbi.nlm.nih.gov/41204470/>]

Nguyen et al. (2022): Lifestyle practices and associated factors among adults with hypertension: Conquering Hypertension in Vietnam-solutions at the grassroots level study.
[<https://pmc.ncbi.nlm.nih.gov/articles/PMC11156363/>]

Liu et al. (2022): Machine Learning Algorithms Identify Demographics, Dietary Features, and Blood Biomarkers Associated with Stroke Records
[<https://doi.org/10.1016/j.jns.2022.120335>]

Lundberg & Lee (2017): A Unified Approach to Interpreting Model Predictions (SHAP)
[<https://arxiv.org/abs/1705.07874>]

Chen & Guestrin (2016): XGBoost: A Scalable Tree Boosting System
[<https://doi.org/10.1145/2939672.2939785>]



TERIMA KASIH