

LAPORAN AKHIR TUGAS BESAR KECERDASAN BUATAN

PENERAPAN *EXPLAINABLE MACHINE LEARNING* UNTUK

PREDIKSI RISIKO STROKE BERBASIS FAKTOR GAYA HIDUP



Disusun oleh:

Fadhil Rusadi (L0124013)
Firizqi Aditya Mulya (L0124016)
Nurman Aqil Wicaksono (L0124139)

Dosen :

Prof. Dr. Wiharto, S.T., M.Kom.

PROGRAM STUDI INFORMATIKA
FAKULTAS TEKNOLOGI INFORMASI DAN SAINS DATA
UNIVERSITAS SEBELAS MARET

2026

ABSTRAK

Stroke merupakan salah satu penyebab kematian tertinggi di dunia. Pendekatan klinis konvensional sering kali mengabaikan kontribusi faktor gaya hidup seperti kualitas tidur, tingkat stres, dan aktivitas fisik. Penelitian ini bertujuan untuk mengukur kontribusi faktor gaya hidup dalam memprediksi risiko stroke menggunakan data survei nasional NHANES 2015-2016. Kami menguji tiga model *machine learning* (Decision Tree, Random Forest, dan XGBoost) di bawah lima skenario fitur dengan optimalisasi *feature selection* (Chi-Square dan ANOVA F-Test) yang memotong fitur dari 31 menjadi 24 fitur signifikan. Penanganan *class imbalance* dilakukan menggunakan SMOTE pada *data training*. Evaluasi performa menggunakan metrik AUC-ROC dan optimasi *decision threshold* berbasis Youden's J-Statistic. Model terbaik yang diperoleh adalah Random Forest dengan 24 fitur yang menghasilkan AUC-ROC sebesar 0,7678, akurasi 70,73%, dan *recall* (sensitivitas) sebesar 77,14% pada *threshold* optimal 0,2344. Metode interpretasi model menggunakan SHAP (*SHapley Additive exPlanations*) menunjukkan bahwa meskipun faktor klinis (usia dan hipertensi) mendominasi, faktor gaya hidup (kualitas tidur dan olahraga) memberikan kontribusi penting dalam penyempurnaan performa model. Model ini diintegrasikan ke dalam aplikasi web berbasis FastAPI dan Next.js yang menampilkan kalkulasi SHAP lokal secara *real-time* untuk memberikan transparansi prediksi bagi pengguna individu. Hasil ini membuktikan bahwa integrasi *explainable machine learning* berbasis gaya hidup mampu menjadi alat skrining risiko stroke dini yang andal dan transparan.

BAB I

PENDAHULUAN

A. Permasalahan Yang Ada

Stroke merupakan keadaan darurat medis akut yang terjadi ketika pembuluh darah yang membawa oksigen dan nutrisi ke otak pecah atau terhalang oleh bekuan darah. Hal ini mengakibatkan sel-sel otak di sekitarnya mati karena kekurangan oksigen dalam hitungan menit. Sebagai salah satu penyebab utama kematian dan disabilitas jangka panjang di tingkat global, stroke menimbulkan beban sosial dan ekonomi yang sangat besar bagi pasien, keluarga, dan sistem kesehatan masyarakat (World Health Organization, 2025).

Faktor klinis seperti riwayat hipertensi diakui secara luas sebagai faktor risiko utama stroke yang dapat dimodifikasi, di mana tingkat keberhasilan pengendalian tekanan darah tersebut sangat dipengaruhi oleh kepatuhan modifikasi gaya hidup harian seperti aktivitas fisik, kebiasaan merokok, dan pola makan (Nguyen *et al.*, 2024). Namun, penapisan risiko stroke konvensional sering kali bersifat reaktif dan hanya berfokus pada parameter medis di laboratorium klinis yang mahal. Faktor-faktor gaya hidup sehari-hari lainnya seperti gangguan pernapasan saat tidur (*sleep apnea*), frekuensi mendengkur yang tinggi, dan gaya hidup kurang bergerak (*sedentary lifestyle*), sering kali diabaikan secara kuantitatif dalam penilaian risiko preventif, meskipun secara klinis terbukti memiliki kontribusi signifikan terhadap peluang terjadinya kejadian stroke pada analisis populasi besar (Liu *et al.*, 2022). Oleh karena itu, diperlukan sebuah sistem penapisan mandiri (*self-assessment*) yang mudah diakses dan mampu memodelkan faktor klinis dasar bersama dengan perilaku hidup sehari-hari untuk mendeteksi risiko stroke secara dini.

Dari sudut pandang komputasi data kesehatan, pemodelan klasifikasi risiko stroke menghadapi kendala ketidakseimbangan kelas (*class imbalance*) yang sangat ekstrim pada dataset populasi umum (seperti survei NHANES), di mana kasus positif stroke hanya berkisar ~3.6% dari total responden. Tanpa penanganan khusus, model machine learning konvensional akan mengalami bias kelas mayoritas (memprediksi seluruh pasien sebagai sehat) sehingga menghasilkan nilai akurasi yang menipu secara visual, namun memiliki tingkat *Recall* (sensitivitas) yang sangat buruk. Kelalaian mendeteksi penderita stroke aktual (*false negative*) di dunia medis memiliki konsekuensi fatal. Selain itu, sifat *black box* dari model ensemble modern (seperti

Random Forest dan XGBoost) sering kali membatasi kepercayaan praktisi medis dan pengguna umum terhadap hasil prediksi model, karena alur pengambilan keputusan internal model yang rumit dan tidak transparan (Lundberg & Lee, 2017).

B. Penyelesaian Masalah Terdahulu

Berbagai penelitian terdahulu telah berupaya memecahkan permasalahan prediksi risiko stroke dengan pendekatan *machine learning*:

1. Shobayo *et al.* (2023) mengembangkan model prediksi stroke berbasis Random Forest dengan memanfaatkan data demografi dan perilaku. Meskipun model tersebut menghasilkan akurasi klasifikasi global yang cukup baik, penelitian ini belum mengeksplorasi metode interpretabilitas model lokal yang mampu menjelaskan secara transparan *mengapa* seseorang diklasifikasikan ke dalam kategori risiko tertentu berdasarkan profil pribadinya.
2. Liu *et al.* (2022) mengidentifikasi korelasi demografi, pola makan, dan biomarker darah untuk stroke. Pemodelan ini terbukti andal dalam konteks klinis, tetapi ketergantungan pada variabel biomarker darah (seperti kadar kolesterol dan glukosa lab) menjadikannya kurang praktis untuk digunakan sebagai alat skrining mandiri yang cepat oleh masyarakat awam secara mandiri di rumah.
3. Huang & Liu (2025) mengevaluasi dan memvalidasi model machine learning prediktif risiko stroke secara mendalam menggunakan basis data survei kesehatan nasional NHANES. Meskipun riset komputasinya sangat kaya, penelitian tersebut masih terbatas sebagai kode eksperimental di *notebook* riset dan belum ditranslasikan menjadi sistem aplikasi interaktif berbasis web yang ramah pengguna.

C. Perbedaan Dengan Apa Yang Akan Dilakukan

Untuk mengatasi batasan-batasan di atas, proyek tugas besar kami mengusung beberapa inovasi penting:

1. Integrasi Gaya Hidup Multi-Domain Tanpa Tes Lab

Model kami mengintegrasikan 12 variabel klinis dasar (seperti usia, riwayat penyakit jantung, dan kisaran tekanan darah yang dapat diukur mandiri) dengan 12 fitur gaya hidup harian yang mencakup domain kualitas tidur (4 fitur), kesehatan mental/stres PHQ-9 (5 fitur), dan aktivitas fisik (3 fitur).

2. Optimalisasi Fitur Statistik Univariat

Berbeda dengan pemilihan fitur manual yang subjektif, kami menerapkan uji Chi-Square (kategorikal) dan ANOVA F-Test (kontinu) untuk memangkas 7 fitur *noise* dari 31 fitur awal menjadi 24 fitur yang terbukti memiliki signifikansi statistik $p < 0.05$ terhadap status stroke.

3. Penalaan Threshold Youden's J-Statistic

Mengatasi bias *class imbalance* pasca-SMOTE dengan menurunkan threshold keputusan dari default 0.50 menjadi 0.2344. Penalaan ini secara dramatis meningkatkan *Recall* (sensitivitas) model dari ~17% menjadi 77.14% demi meminimalkan risiko *false negative* medis.

4. Integrasi Real-Time Local SHAP (Explainable AI)

Kami mengintegrasikan pustaka SHAP (Lundberg & Lee, 2017) langsung di dalam backend API FastAPI. Setiap kali pengguna mengisi kuis di frontend Next.js, backend akan menghitung nilai SHAP lokal secara dinamis (real-time) dan menyajikan bagan kontribusi fitur dua arah (*dual-direction SHAP bar chart*) di halaman hasil untuk memberikan penjelasan transparan mengenai alasan di balik skor risiko stroke pengguna tersebut.

BAB II

METODE

A. Alur Preprocessing & Penanganan Data Leakage

Dataset dasar dikonstruksi dari survei NHANES (National Health and Nutrition Examination Survey) 2015-2016 dengan menggabungkan 10 file modul CDC terpisah (seperti demografi, pemeriksaan fisik, tekanan darah, riwayat medis, kuesioner tidur, stres PHQ-9, dan aktivitas fisik) berdasarkan kode ID responden (SEQN).

Untuk menjamin keandalan evaluasi model dan menghindari kebocoran data (*data leakage*), seluruh tahapan preprocessing dilakukan secara ketat dengan alur berikut (juga ditunjukkan di Gambar 2.1):

1. Stratified Split

Dataset dibagi menjadi data latih (*training set*) sebesar 80% dan data uji (*test set*) sebesar 20% secara stratified berdasarkan target kelas stroke. Pembagian ini memastikan distribusi kelas target tetap seimbang di kedua subset.

2. Imputasi Missing Value


Menggunakan nilai *Median* untuk variabel kontinu dan *Modus* untuk variabel kategorikal/biner pada subset training, yang kemudian diterapkan pada subset test. Durasi menit olahraga diimputasi dengan nilai 0 jika responden menjawab tidak berolahraga.

3. Standardisasi Skala

Standardisasi skala fitur numerik kontinu menggunakan *StandardScaler* untuk mencegah bias akibat perbedaan satuan (seperti lingkaran pinggang dalam cm dan tekanan darah dalam mmHg). Scaler hanya dilatih (*fit*) pada data training dan kemudian digunakan untuk mengubah (*transform*) data uji.

4. SMOTE (Synthetic Minority Over-sampling Technique)

Penyeimbangan kelas target (~96.4% sehat vs ~3.6% stroke) dilakukan dengan menerapkan SMOTE hanya pada data training pasca-scaling. Data uji dibiarkan asli tanpa SMOTE agar performa pengujian tetap mencerminkan populasi riil di lapangan.



Gambar 2.1. Alur Preprocessing & Penanganan Data Leakage

B. Seleksi Fitur Statistik (Feature Selection)

Kami menyeleksi fitur menggunakan pendekatan statistik univariat dengan ambang batas signifikansi $p < 0.05$ terhadap variabel target stroke:

Uji Chi-Square:

$$\chi^2 = \sum \frac{(O-E)^2}{E}$$

Di mana O adalah nilai observasi dan E adalah nilai ekspektasi. Uji ini mengevaluasi apakah keberadaan riwayat klinis atau kebiasaan gaya hidup tertentu secara signifikan memengaruhi kecenderungan stroke.

Uji ANOVA F-Test digunakan untuk fitur kontinu:

$$F = \frac{\text{Variansi Antar-Grup}}{\text{Variansi Dalam-Grup}}$$

Uji ini mengukur apakah rata-rata nilai numerik (seperti lingkaran pinggang atau tekanan darah) memiliki perbedaan yang signifikan antara kelompok penderita stroke dan kelompok sehat.

Uji ini berhasil mengeliminasi 7 fitur noise, yaitu jenis kelamin (gender), ras (race), BMI (bmi), status perokok aktif (current_smoker), durasi tidur (sleep_hours), kerja fisik berat (vigorous_work), dan menit sedentary (sedentary_min). Penyusutan dimensi ini menghasilkan 24 fitur teroptimal (12 klinis, 4 tidur, 5 stres PHQ-9, 3 aktivitas fisik).

C. Eksperimen Model Klasifikasi & Parameter

Eksperimen membandingkan tiga algoritma dengan pendekatan matematis yang berbeda pada 5 skenario kombinasi fitur:

1. Decision Tree

Membagi dataset secara rekursif berdasarkan batas *splitting* terbaik (Gini Impurity). Kami menggunakan parameter `max_depth=6` untuk membatasi kompleksitas pohon, `class_weight='balanced'` untuk penyesuaian bobot kelas, dan `random_state=42`.

2. Random Forest

Algoritma *Ensemble Bagging* yang melatih 200 Decision Tree independen pada subset sampel bootstrap acak. Parameter yang disetel: `n_estimators=200`, `max_depth=8`, `class_weight='balanced'`, dan `n_jobs=-1`.

3. XGBoost (Extreme Gradient Boosting)

Algoritma *Ensemble Boosting* yang membangun pohon secara sekuensial untuk meminimalkan residual error dari pohon sebelumnya (Chen & Guestrin, 2016). Parameter yang disetel: `n_estimators=200`, `max_depth=6`, `learning_rate=0.05`, `scale_pos_weight=10`, dan `eval_metric='logloss'`.

D. Penalaan Threshold & Pustaka SHAP (XAI)

Untuk mengatasi class imbalance, batas keputusan probabilitas ditala menggunakan indeks Youden's J-Statistic pada kurva ROC:

$$J(\text{threshold}) = \text{True Positive Rate}(\text{threshold}) + \text{True Negative Rate}(\text{threshold}) - 1$$

Ambang batas optimal yang terpilih untuk model terbaik adalah 0.2344.

Interpretabilitas model didasarkan pada metode SHAP (SHapley Additive exPlanations) yang berakar pada teori permainan kooperatif (*cooperative game theory*) (Lundberg & Lee, 2017). Nilai SHAP mengalokasikan kontribusi yang adil untuk setiap variabel terhadap perubahan output prediksi dari nilai rata-rata dasar (*expected value*):

$$g(z') = \phi_0 + \sum_{i=1}^M \phi_i z'_i$$

Di mana ϕ adalah *expected value* model, ϕ_i adalah nilai SHAP untuk fitur i , dan menyatakan keberadaan fitur tersebut.

Di backend FastAPI, pustaka shap memuat model Random Forest dan menginisialisasi TreeExplainer(model) saat startup. Pada setiap request POST ke /predict, backend menghitung nilai SHAP lokal dari input yang diskalakan secara instan dan mengirimkannya ke frontend.

E. Arsitektur Sistem Web App

Sistem diimplementasikan secara terpisah (*decoupled*) dengan arsitektur modern:

1. Backend (FastAPI)

Memuat model Random Forest Skenario E (24 fitur), Standard Scaler, dan metadata kelompok fitur. Kontainerisasi dilakukan menggunakan Docker dan dihosting di Hugging Face Spaces.

2. Frontend (Next.js & Tailwind CSS)

Menyediakan alur kuis multi-step, visualisasi Decision Threshold Gauge, dan visualisasi bar kontribusi SHAP. Di-deploy di platform Vercel dengan fitur CI/CD otomatis.

BAB III

HASIL DAN PEMBAHASAN

A. Dampak Penerapan Feature Selection

Berdasarkan pengujian pada subset data uji, penyederhanaan dimensi fitur dari 31 menjadi 24 secara konsisten meningkatkan generalisasi model dan mengurangi overfitting di hampir seluruh skenario eksperimen. Rincian perbandingan metrik kinerja sebelum dan sesudah penerapan feature selection disajikan pada Tabel 3.1 berikut:

Tabel 3.1: Perbandingan Kinerja Sebelum vs. Sesudah Feature Selection (FS)

Skenario	Domain Fitur	Model Terbaik	Metrik Evaluasi	Sebelum FS	Setelah FS	Selisih
Skenario A	Klinis & Demografi (Baseline)	XGBoost	AUC-ROC	0,69661	0,8232	+0,1271
Skenario B	Klinis + Kualitas Tidur	XGBoost	AUC-ROC	0,7375	0,8139	+0,0764
Skenario C	Klinis + Stres & Depresi	XGBoost	AUC-ROC	0,7361	0,8064	+0,0703
		XGBoost	Tuned F1-Score	0,1157	0,2101	+0,0944
Skenario D	Klinis + Aktivitas Fisik	XGBoost	AUC-ROC	0,7007	0,7831	+0,0824
Skenario E	Klinis + Semua Gaya Hidup	Random Forest	AUC-ROC	0,7819	0,7678	-0,0141

Berdasarkan matriks perbandingan pada Tabel 3.1 di atas serta perbandingan visual antar-model yang disajikan pada Gambar 3.1, pemangkasan fitur noise melalui seleksi statistik memberikan dua implikasi utama:


1. Peningkatan Kinerja pada Skenario Parsial (A, B, C, D)

Mereduksi jumlah fitur meningkatkan generalisasi model ensemble secara signifikan, terutama pada model berbasis boosting (XGBoost) yang sangat sensitif terhadap variabel redundan. Peningkatan dramatis terlihat pada


F1-Score Skenario C (+81.59%) dan AUC-ROC Skenario A (+12.71%). Hal ini menunjukkan batas keputusan (decision boundary) yang dibentuk model menjadi lebih kokoh tanpa pengaruh variabel pengganggu.

2. Efisiensi Komputasi pada Skenario Komprehensif (E)

Meskipun Skenario E mengalami sedikit penurunan nilai AUC-ROC sebesar 1.41% pada model Random Forest, model yang dihasilkan menjadi jauh lebih ringkas (parsimonious). Hal ini mempercepat waktu pelatihan (training time), mengurangi konsumsi memori saat di-deploy di web app, serta menyederhanakan jumlah pertanyaan kuis sehingga meningkatkan kenyamanan pengisian (user experience) tanpa mengorbankan performa klasifikasi secara signifikan. Peta intensitas nilai kinerja model secara keseluruhan untuk semua skenario juga divisualisasikan dalam bentuk matriks heatmap pada Gambar 3.2.




Gambar 3.1. Perbandingan AUC-ROC antar Skenario dan Model Klasifikasi (Sesudah Feature Selection)



Gambar 3.2. Heatmap Matriks AUC-ROC Semua Kombinasi Model dan Skenario (24 Fitur)

B. Pemilihan Model Terbaik & Penalaan Threshold

Pada skenario gabungan seluruh gaya hidup (Skenario E) dengan 24 fitur, model Random Forest mencatatkan kinerja terbaik dengan nilai AUC-ROC = 0.7678 (mengungguli XGBoost sebesar 0.7286 dan Decision Tree sebesar 0.6624 pada skenario yang sama). Penerapan threshold keputusan tuned 0.2344 memberikan dampak yang sangat krusial bagi aplikasi skrining medis ini, sebagaimana dirinci pada Tabel 3.2. Kurva karakteristik keputusan (ROC Curve) pada Skenario E dapat dilihat pada Gambar 3.3:



Gambar 3.3. Kurva ROC Model Klasifikasi pada Skenario E (AUC-ROC Random Forest = 0.7678)

Tabel 3.2. Perbandingan Kinerja Model Random Forest Skenario E pada Berbagai Threshold

Metrik Evaluasi	<i>Threshold 0,50</i>	<i>Threshold 0,234</i>	Selisih Perubahan
Akurasi (Accuracy)	90,57%	70,73%	-19,84%
Sensitivitas (Recall)	17,14%	77,14	+60%
Presisi (Precision)	8,22%	8,25	+0.30%
F1-Score (Keseimbangan)	11,11%	15,34	+4.23%
AUC-ROC	0,7678	0,7678	Tetap (0.00%)

Berdasarkan Tabel 3.2, perubahan threshold keputusan ini melahirkan implikasi klinis yang sangat penting:

1. Peningkatan Recall (Sensitivitas) secara masif sebesar +60.00% (dari 17.14% ke 77.14%) menjamin model dapat mendeteksi sebagian besar penderita stroke aktual secara agresif guna meminimalkan risiko false negative (terlewatnya pasien stroke yang memerlukan penanganan preventif).
2. Penurunan Akurasi dari 90.57% menjadi 70.73% merupakan konsekuensi logis (trade-off) dari klasifikasi yang lebih sensitif, di mana model mendeteksi lebih banyak status positif demi keselamatan pasien.
3. Presisi yang stabil pada angka 8.52% tetap menunjukkan efektivitas model karena nilai ini 2.3 kali lipat lebih tinggi dibandingkan probabilitas acak populasi umum NHANES yang hanya ~3.6%.


C. Analisis SHAP Global & Pengaruh Kelompok Fitur

Berdasarkan pengujian nilai SHAP global pada model Random Forest Skenario E, tingkat kepentingan absolut dari masing-masing 20 fitur utama secara global disajikan pada Gambar 3.4. Sementara itu, tingkat signifikansi dan arah pengaruh kelompok fitur tersebut diurutkan sebagai berikut:


1. Kelompok Klinis (Mean SHAP: 0.3204)
Usia (age) mendominasi sebagai fitur terpenting, disusul oleh riwayat hipertensi (hypertension). Pada beeswarm plot (Gambar 3.5), titik merah (usia tua dan adanya riwayat hipertensi) berkumpul di sisi kanan (SHAP > 0), secara konsisten meningkatkan prediksi risiko stroke.
2. Kelompok Kualitas Tidur (Mean SHAP: 0.0782)
Menempati urutan kedua. Keluhan henti napas saat tidur (sleep_apnea) dan frekuensi mendengkur (snoring_freq) tinggi terbukti secara signifikan meningkatkan risiko stroke akibat penurunan saturasi oksigen otak yang berulang (Liu *et al.*, 2022).
3. Kelompok Aktivitas Fisik (Mean SHAP: 0.0728)
Tidak adanya olahraga berat (vigorous_leisure) maupun olahraga sedang (moderate_leisure) rutin menempatkan titik data di sisi kanan positif SHAP, menunjukkan bahwa gaya hidup sedentary merupakan pemicu peningkatan risiko stroke yang signifikan.
4. Kelompok Stres (Mean SHAP: 0.0409)

Gejala kehilangan minat (stress_anhedonia) dan kelelahan fisik (stress_fatigue) PHQ-9 berkontribusi pada peningkatan risiko psikologis, meskipun memiliki dampak terkecil dibanding kelompok lainnya.


Secara kumulatif, perbandingan nilai kontribusi rata-rata dari keempat kelompok besar fitur tersebut disajikan pada Gambar 3.6.



Gambar 3.4. SHAP Global Feature Importance (Rata-rata Dampak Absolut pada Output Model).



Gambar 3.5: SHAP Beeswarm Plot Skenario E (Menunjukkan arah pengaruh nilai/warna fitur terhadap risiko).



Gambar 3.6: Kontribusi Kumulatif Rata-rata Berdasarkan Kelompok Fitur (Klinis, Tidur, Aktivitas Fisik, Stres).

D. Implementasi XAI & Threshold di Web App


Dalam antarmuka web, model AI ini ditonjolkan secara interaktif pada halaman hasil:

- 1. Bilah Threshold Youden**


Menggambarkan letak probabilitas risiko stroke pengguna pada bar 0-100% dengan penanda garis merah batas risiko optimal di titik 23.44%. Jika probabilitas ≥ 23.44 , status akan langsung berubah menjadi "Risiko Tinggi". Pengguna juga disajikan informasi edukatif mengenai alasan penyesuaian threshold statistik ini.

- 2. Bagan Batang Dua Arah SHAP Lokal**

Menampilkan 6 faktor terbesar yang menggeser risiko pengguna. Misalnya, jika pengguna berolahraga rutin dan berpendidikan tinggi, bagan menunjukkan batang hijau yang memanjang ke kiri (contoh: Olahraga Berat -14.0% dan Tingkat Pendidikan -3.5%). Sebaliknya, jika tensi pengguna tinggi, bagan menampilkan batang merah yang memanjang ke kanan (contoh: Tekanan Darah Sistolik +3.6%). Hal ini menerjemahkan model machine learning yang rumit menjadi wawasan kesehatan yang transparan dan dapat dipahami secara langsung oleh pengguna sebagaimana ditunjukkan pada contoh antarmuka dashboard hasil di Gambar 3.7 dan 3.8.



Gambar 3.7. Dashboard hasil website MediTrust yang menampilkan Risk Gauge dengan batas Youden's Threshold (23.44%)



Gambar 3.8. Dashboard hasil website MediTrust yang menampilkan Horizontal Dual-Direction SHAP Bar Chart secara *real-time*

KESIMPULAN

Penelitian ini berhasil membuktikan bahwa integrasi faktor gaya hidup (kualitas tidur, stres, dan aktivitas fisik) secara kolektif dengan parameter klinis dasar mampu meningkatkan performa dan interpretabilitas model prediksi risiko stroke. Penerapan seleksi fitur statistik (Chi-Square & ANOVA F-Test) sukses mereduksi dimensi dari 31 menjadi 24 fitur signifikan, meminimalkan *overfitting*, serta meningkatkan kualitas sampling SMOTE. Model Random Forest Skenario E (24 fitur) menghasilkan kinerja terbaik dengan nilai AUC-ROC sebesar 0.7678. Penalaan ambang batas keputusan optimal Youden's J-Statistic pada 0.2344 terbukti krusial untuk penapisan medis awal dengan meningkatkan Recall model secara masif hingga 77.14%. Terakhir, integrasi visualisasi threshold keputusan dan bagan kontribusi fitur SHAP lokal secara real-time pada web app berhasil menjembatani sifat "kotak hitam" (*black box*) model machine learning menjadi sistem penapisan dini yang transparan, tepercaya, dan edukatif bagi pengguna individu.

REFERENSI

Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785–794. [<https://doi.org/10.1145/2939672.2939785>]

Huang, J., & Liu, W. (2025). Development and validation of a machine learning model to predict stroke risk based on the NHANES database. *Medicine*, 104(45), e45800. [<https://doi.org/10.1097/MD.00000000000045800>]

Liu, J., Chou, E. L., Lau, K. K., Woo, P. Y. M., Li, J., & Chan, K. H. K. (2022). Machine learning algorithms identify demographics, dietary features, and blood biomarkers associated with stroke records. *Journal of the Neurological Sciences*, 440, 120335. [<https://doi.org/10.1016/j.jns.2022.120335>]

Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems (NeurIPS 2017)*, 30, 4765–4774. [<https://arxiv.org/abs/1705.07874>]

Nguyen, P. H., Goldberg, R. J., Allison, J. J., Nguyen, D. B., Tran, H. T., Tran, O. M., et al. (2024). Lifestyle practices and associated factors among adults with hypertension: Conquering Hypertension in Vietnam-solutions at the grassroots level study. *PLoS ONE*, 19(6), e0303354. [<https://doi.org/10.1371/journal.pone.0303354>]

Shobayo, O., Zachariah, O., Odusami, M. O., & Ogunleye, B. (2023). Prediction of Stroke Disease with Demographic and Behavioural Data Using Random Forest Algorithm. *Analytics*, 2(3), 604–617. [<https://doi.org/10.3390/analytics2030034>]

World Health Organization. (2025). Stroke. <https://www.who.int/news-room/fact-sheets/detail/stroke>

LAMPIRAN

Live website: <https://nhanes-stroke-dataset.vercel.app>

Repository: <https://github.com/Adityamulyaf/NHANES-Stroke-Dataset.git>